FACULTAD DE ESTUDIOS ESTADÍSTICOS

UNIVERSIDAD
COMPLUTENSE
MADRID

GRADO EN CIENCIA DE LOS DATOS APLICADA

APRENDIZAJE NO SUPERVISADO

Curso Académico 2025-26

Práctica 1

Laura López Rodríguez

Práctica 1: ***Análisis base de datos socioeconómica*.**

ÍNDICE

1. **Explicación del dataset**

2. **Descripción de las variables**

3. **Depuración del dataset**
   3.1 Ausentes y atípicos

4. **Análisis de componentes principales**
   4.1 Matriz de correlaciones
   4.2 Número de componentes
   4.3 Análisis con número de componentes
      a) Expresión primera componente
      b) Correlaciones de las variables con las componentes
      c) Gráfico de correlación de las variables con las componentes
      d) Gráfico de planos.

5. **Análisis factorial**
   5.1 Índice KMO
   5.2 Mejora del índice KMO
   5.3 Análisis factorial sobre la matriz de correlaciones.
      - Método de Componentes Principales.
      - Método de del Factor Principal.
      - Método de Máxima Verosimilitud.
      5.3.1 Para el mejor método:
         a) Porcentaje de la varianza explicado
         b) PATHDIAGRAM
         c) Gráficos de planos.
         d) Comunalidad.

   5.4 Rotación
         e) PATHDIAGRAM
         f) Gráficos de planos
         g) Carga de variables sobre factores
         h) Raíz de la media del cuadrado de los residuales (RMSR)
         i) Coeficientes

6. **Análisis de correspondencias simples**

1. EXPLICACIÓN DE LA BASE DE DATOS

La base de datos seleccionada es cancer.csv que recoge los datos acerca de diferentes características socioeconómicas de distintas regiones, extraídas de the American Community Survey (census.gov), clinicaltrials.gov, y cancer.gov.

2. DESCRIPCIÓN DE LAS VARIABLES

Las variables hacen referencia a:

VARIABLE	DESCRIPCIÓN
ID	Variable identificadora
deathRate	Representa la mortalidad media de cáncer, por cada 100 000 habitantes.
medIncome	Mediana de los ingresos de la región
popEst2015	Población de la región
propertyPercent	Porcentaje de población en situación de pobreza
studyPerCap	Ensayos clínicos relacionados con el cáncer realizados por cada 100 000 habitantes
MedianAge	Edad mediana
AvgHouseholdSize	Tamaño medio de los hogares
PercentMarried	Porcentaje de habitantes casados
PctHS25_Over	Porcentaje de residentes por encima de los 25 años con (máximo) título de bachillerato
PctUnemployed16_Over	Porcentaje de residentes de más de 16 años en paro
PctPrivateCoverage	Porcentaje de residentes con seguro de salud privado
BirthRate	Tasa de natalidad

Contamos con un número total de 13 variables que trataremos de reducir con el objetivo de reducir la dimensión de la base de datos de tal forma que podamos pasar de las p=13 variables originales a m < p variables nuevas que sean combinaciones lineales de las originales, estén incorreladas entre sí y capturen la mayor parte de la varianza.

3. DEPURACIÓN DE LA BASE DE DATOS

3.1 AUSENTES Y ATÍPICOS

Mediante SAS realizamos el tratamiento de datos atípicos y ausentes, así como una primera visión de estadísticos descriptivos como la media y el número de missings.

```
PROC MEANS
DATA=no_super.cancer mean NMISS;
RUN;
```

Variable	N Miss
deathRate	0
medIncome	0
popEst2015	0
povertyPercent	0
studyPerCap	0
MedianAge	0
AvgHouseholdSize	0
PercentMarried	0
PctHS25_Over	0
PctUnemployed16_Over	0
PctPrivateCoverage	0
BirthRate	0
ID	0

Comprobamos que no tenemos valores ausentes.

Pasamos a la detección de outliers.

```
/* comprobamos si hay datos atípicos llamando a la MACRO*/
%outliers_mult (data=no_super.cancer, var= deathRate medIncome popEst2015
povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate, id=ID);

PROC PRINT data=outliers;
where conclusion ne "caso logico"; /*multivariante*/
RUN;

PROC PRINT data= Univariante;
where (llamada= "PROBLEMAS"); /*univariante*/
RUN;
```

Obs	ID	OBSERVACION	DISTANCIA	RANGOS	PVALOR	CONCLUSION
468	388	388	35.280	468	0.00042	caso atípico
469	194	194	35.316	469	0.00042	caso atípico
470	174	174	35.709	470	0.00036	caso atípico
471	24	24	36.044	471	0.00032	caso atípico
472	124	124	36.428	472	0.00028	caso atípico
473	176	176	37.575	473	0.00018	caso atípico
474	412	412	38.002	474	0.00015	caso atípico
475	222	222	38.100	475	0.00015	caso atípico
476	495	495	38.600	476	0.00012	caso atípico
477	274	274	39.830	477	0.00008	caso atípico
478	123	123	41.563	478	0.00004	caso atípico
479	492	492	42.351	479	0.00003	caso atípico
480	394	394	44.487	480	0.00001	caso atípico
481	472	472	45.777	481	0.00001	caso atípico
482	210	210	46.269	482	0.00001	caso atípico
483	366	366	46.270	483	0.00001	caso atípico
484	166	166	47.702	484	0.00000	caso atípico
485	98	98	49.357	485	0.00000	caso atípico
486	34	34	49.501	486	0.00000	caso atípico
487	177	177	51.051	487	0.00000	caso atípico
488	122	122	55.457	488	0.00000	caso atípico
489	260	260	55.888	489	0.00000	caso atípico
490	256	256	57.560	490	0.00000	caso atípico
491	300	300	58.468	491	0.00000	caso atípico

492	113	113	63.263	492	0.00000	caso atípico
493	30	30	76.133	493	0.00000	caso atípico
494	101	101	80.310	494	0.00000	caso atípico
495	182	182	82.700	495	0.00000	caso atípico
496	426	426	94.267	496	0.00000	caso atípico
497	387	387	101.156	497	0.00000	caso atípico
498	226	226	107.417	498	0.00000	caso atípico
499	319	319	144.272	499	0.00000	caso atípico
500	384	384	240.847	500	0.00000	caso atípico

Hemos detectado 33 atípicos a nivel multivariante, por tanto, para darnos una primera idea de si estos outliers pueden afectar a la media (ya que tomaremos una decisión sobre los outliers con los resultados de los factores), comparamos medias de con y sin outliers.
Si las medias varían mucho, es posible que los outliers estén provocando grandes efectos sobre la media, desplazándola hacia esos valores atípicos.

```
data no_super.cancer_sin_outliers;
    set no_super.cancer;
    where ID not in (
388 194 174 24 124 176 412 222 495 274
123 492 394 472 210 366 166 98 34 177
122 260 256 300 113 30 101 182 426 387
226 319 384); /*cogemos todas las observaciones que no son estos ID*/
run;
```

```
PROC MEANS
DATA=no_super.cancer_sin_outliers mean;
RUN;
```

Variable	Mean
deathRate	175.4370450
medIncome	48764.87
popEst2015	99243.22
povertyPercent	15.9537473
studyPerCap	140.3590064
MedianAge	42.0578158
AvgHouseholdSize	2.4455422
PercentMarried	51.2000000
PctHS25_Over	33.3680942
PctUnemployed16_Over	7.9507495
PctPrivateCoverage	66.8993576
BirthRate	5.3743646
ID	250.8115632

```
PROC MEANS
DATA=no_super.cancer mean;
RUN;
```

Variable	Mean
deathRate	175.5956000
medIncome	48940.73
popEst2015	118399.07
povertyPercent	16.1366000
studyPerCap	185.0949678
MedianAge	46.7112000
AvgHouseholdSize	2.4221586
PercentMarried	50.8380000
PctHS25_Over	33.2064000
PctUnemployed16_Over	8.0390000
PctPrivateCoverage	66.5758000
BirthRate	5.3903876
ID	250.5000000

Las medias no parecen diferir mucho. Además, podemos comprobar que el centro de gravedad no se encuentra en el 0 por lo que deberemos centrarlas: $Y_i = X_i - \bar{X}$

4. ANÁLISIS DE COMPONENTES PRINCIPALES SOBRE LA MATRIZ DE CORRELACIONES

4.1) Observando la matriz de correlaciones, ¿Cuáles son las variables más correlacionadas de forma positiva? ¿Cuáles son las variables más correlacionadas de forma negativa?

```
PROC CORR
data=no_super.cancer_sin_outliers;
var deathRate medIncome popEst2015 povertyPercent studyPerCap MedianAge
AvgHouseholdSize PercentMarried PctHS25_Over PctUnemployed16_Over
PctPrivateCoverage BirthRate;
RUN;
```

Pearson Correlation Coefficients, N = 467
Prob > |r| under H0: Rho=0

	deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
deathRate	1.00000	-0.37112 <.0001	-0.13706 0.0030	0.36908 <.0001	0.00338 0.9419	0.01748 0.7063	-0.00263 0.9548	-0.28038 <.0001	0.41419 <.0001	0.44636 <.0001	-0.37658 <.0001	-0.18049 <.0001
medIncome	-0.37112 <.0001	1.00000	0.43722 <.0001	-0.80158 <.0001	0.01542 0.7396	-0.18913 <.0001	0.21819 <.0001	0.31014 <.0001	-0.48324 <.0001	-0.39948 <.0001	0.70129 <.0001	0.08470 0.0674
popEst2015	-0.13706 0.0030	0.43722 <.0001	1.00000	-0.20089 <.0001	0.12775 0.0057	-0.29752 <.0001	0.20748 <.0001	-0.15252 0.0009	-0.40328 <.0001	0.03653 0.4310	0.18681 <.0001	-0.06617 0.1534
povertyPercent	0.36908 <.0001	-0.80158 <.0001	-0.20089 <.0001	1.00000	-0.00802 0.8628	-0.15030 0.0011	0.05091 0.2722	-0.58321 <.0001	0.24128 <.0001	0.57404 <.0001	-0.79812 <.0001	-0.14054 0.0023
studyPerCap	0.00338 0.9419	0.01542 0.7396	0.12775 0.0057	-0.00802 0.8628	1.00000	-0.12197 0.0083	-0.01910 0.6806	-0.09810 0.0341	-0.19818 <.0001	0.03055 0.5102	0.06032 0.1932	-0.03532 0.4464
MedianAge	0.01748 0.7063	-0.18913 <.0001	-0.29752 <.0001	-0.15030 0.0011	-0.12197 0.0083	1.00000	-0.41700 <.0001	0.52844 <.0001	0.39656 <.0001	-0.06717 0.1472	-0.03903 0.4000	-0.01929 0.6776
AvgHouseholdSize	-0.00263 0.9548	0.21819 <.0001	0.20748 <.0001	0.05091 0.2722	-0.01910 0.6806	-0.41700 <.0001	1.00000	-0.15037 0.0011	-0.13314 0.0039	0.14420 0.0018	-0.13314 0.0039	0.00461 0.9208
PercentMarried	-0.28038 <.0001	0.31014 <.0001	-0.15252 0.0009	-0.58321 <.0001	-0.09810 0.0341	0.52844 <.0001	-0.15037 0.0011	1.00000	0.14552 0.0016	-0.42718 <.0001	0.38640 <.0001	0.24538 <.0001
PctHS25_Over	0.41419 <.0001	-0.48324 <.0001	-0.40328 <.0001	0.24128 <.0001	-0.19818 <.0001	0.39656 <.0001	-0.13314 0.0039	0.14552 0.0016	1.00000	0.16085 0.0005	-0.32733 <.0001	-0.02664 0.5658
PctUnemployed16_Over	0.44636 <.0001	-0.39948 <.0001	0.03653 0.4310	0.57404 <.0001	0.03055 0.5102	-0.06717 0.1472	0.14420 0.0018	-0.42718 <.0001	0.16085 0.0005	1.00000	-0.63734 <.0001	-0.23287 <.0001
PctPrivateCoverage	-0.37658 <.0001	-0.70129 <.0001	0.18681 <.0001	-0.79812 <.0001	0.06032 0.1932	-0.03903 0.4000	-0.13314 0.0039	0.38640 <.0001	-0.32733 <.0001	-0.63734 <.0001	1.00000	0.05915 0.2020
BirthRate	-0.18049 <.0001	0.08470 0.0674	-0.06617 0.1534	-0.14054 0.0023	-0.03532 0.4464	-0.01929 0.6776	0.00461 0.9208	0.24538 <.0001	-0.02664 0.5658	-0.23287 <.0001	0.05915 0.2020	1.00000

Observando la matriz de correlaciones, las dos variables más correlacionadas de forma negativa son **medIncome** y **povertyPercent** con un coeficiente de correlación de -0.80, lo que nos indica que a mayor porcetanje de personas en situación de pobreza, menor ingreso. Por otro lado, las dos variables más correlacionadas de forma positiva son **PctPrivateCoverage** y **medIncome** con un coeficiente de correlación de 0.70129, a mayor ingreso, mayor porcentaje de residentes con seguro de salud privado.

4.2) ¿Cuál es el número adecuado de componentes? Justifique la respuesta. (al menos un 70% de la varianza total explicada)

```
/*sin outliers*/
PROC PRINCOMP
DATA=no_super.cancer_sin_outliers OUTSTAT=Stat  OUT=results;
var deathRate medIncome popEst2015 povertyPercent studyPerCap MedianAge
AvgHouseholdSize PercentMarried PctHS25_Over PctUnemployed16_Over
PctPrivateCoverage BirthRate;
RUN;
```

Eigenvalues of the Correlation Matrix				
	Eigenvalue	Difference	Proportion	Cumulative
1	3.82185605	1.44745083	0.3185	0.3185
2	2.37440522	1.24410315	0.1979	0.5164
3	1.13030207	0.07897924	0.0942	0.6105
4	1.05132283	0.18976703	0.0876	0.6982
5	0.86155580	0.10973058	0.0718	0.7700
6	0.75182522	0.05683628	0.0627	0.8326
7	0.69498893	0.22444823	0.0579	0.8905
8	0.47054070	0.14345783	0.0392	0.9297
9	0.32708287	0.07739971	0.0273	0.9570
10	0.24968316	0.07724488	0.0208	0.9778
11	0.17243828	0.07843942	0.0144	0.9922
12	0.09399886		0.0078	1.0000

Si seleccionamos el número de factores según la varianza acumulada hasta el 70%, vemos que el número de componentes adecuado es de 5 factores.

Eigenvectors												
	Prin1	Prin2	Prin3	Prin4	Prin5	Prin6	Prin7	Prin8	Prin9	Prin10	Prin11	Prin12
deathRate	-.312253	0.026063	-.166101	0.330664	0.386343	-.411799	0.443594	-.208212	-.439736	-.111618	0.003736	0.009113
medIncome	0.432922	-.180374	0.001878	0.275257	0.118371	-.013900	0.067866	-.233570	0.153050	0.156535	-.467258	0.603864
popEst2015	0.157226	-.396381	-.157457	0.212140	0.106828	0.502144	0.406932	0.534370	-.109464	-.101504	0.095234	-.048006
povertyPercent	-.458551	-.102346	0.088399	-.212125	-.158694	0.074339	-.061014	0.138324	-.142630	-.194331	0.227513	0.750339
studyPerCap	0.021968	-.172034	-.494783	-.502216	0.615959	-.057901	-.270638	0.088705	0.054036	0.040129	-.053198	0.040717
MedianAge	-.003527	0.524356	-.210437	0.120017	0.082418	0.449575	-.096599	-.065314	-.344055	0.536805	0.135428	0.137727
AvgHouseholdSize	-.005338	-.352700	0.472424	0.339481	0.338298	-.054536	-.530196	0.078175	-.209559	0.183351	0.228343	-.053211
PercentMarried	0.277551	0.414927	0.086928	0.124518	0.278575	0.226645	-.192686	-.075632	-.048464	-.738199	0.065861	0.065543
PctHS25_Over	-.242395	0.395925	0.080509	0.264782	0.246133	-.205971	0.029633	0.557702	0.510731	0.117295	-.092736	0.098883
PctUnemployed16_Over	-.367187	-.170947	-.083405	0.201589	0.177237	0.381110	0.064127	-.505026	0.539750	-.009973	0.240801	-.055853
PctPrivateCoverage	0.441659	0.024352	-.185356	0.056232	-.059055	-.338889	0.113380	-.012474	0.174566	0.083668	0.754470	0.169654
BirthRate	0.117840	0.107305	0.610058	-.462177	0.355529	0.101130	0.458960	-.084874	0.025978	0.160584	0.085819	0.022766

Para ver si los outliers afectan mucho a los resultados, hacemos la descomposición en componentes principales con la base de datos que contiene los outliers.

```
/*con outliers*/
PROC PRINCOMP
DATA=no_super.cancer   OUTSTAT=Stat  OUT=Crime1;
var deathRate medIncome popEst2015 povertyPercent studyPerCap MedianAge
AvgHouseholdSize PercentMarried PctHS25_Over PctUnemployed16_Over
PctPrivateCoverage BirthRate;
RUN;
```

Eigenvalues of the Correlation Matrix				
	Eigenvalue	Difference	Proportion	Cumulative
1	3.76883924	1.97998822	0.3141	0.3141
2	1.78885103	0.73879058	0.1491	0.4631
3	1.05006045	0.02849652	0.0875	0.5506
4	1.02156393	0.02942443	0.0851	0.6358
5	0.99213950	0.09367421	0.0827	0.7185
6	0.89846529	0.12870230	0.0749	0.7933
7	0.76976299	0.16299743	0.0641	0.8575
8	0.60676555	0.09939348	0.0506	0.9080
9	0.50737208	0.20841388	0.0423	0.9503
10	0.29895819	0.11055093	0.0249	0.9752
11	0.18840726	0.07959277	0.0157	0.9909
12	0.10881449		0.0091	1.0000

Eigenvectors												
	Prin1	Prin2	Prin3	Prin4	Prin5	Prin6	Prin7	Prin8	Prin9	Prin10	Prin11	Prin12
deathRate	0.311089	-.101866	-.274901	0.256938	0.122085	0.260000	0.475474	-.505226	0.213734	-.375668	-.024399	0.004822
medIncome	-.431061	0.220272	-.072120	0.004130	0.080785	0.165382	0.205920	-.194451	-.219047	0.218184	-.529131	0.520376
popEst2015	-.081230	0.525761	-.025432	-.058924	0.084005	-.178164	0.550954	0.492367	0.329739	-.110372	0.083659	-.013207
povertyPercent	0.462974	0.104665	0.135325	-.093952	-.100941	-.150113	-.192122	0.025789	0.103597	-.164252	0.160519	0.783444
studyPerCap	0.000447	0.122577	0.020592	0.885977	0.269397	-.233265	-.221890	0.131715	-.036915	0.009333	-.057324	0.035900
MedianAge	-.003486	-.148566	0.038120	-.314735	0.904651	-.187127	-.088989	-.066850	0.103126	-.004026	-.014703	0.027192
AvgHouseholdSize	0.008109	0.334400	0.437131	0.053033	0.185554	0.761221	-.192811	0.023837	0.120018	0.000689	0.161512	-.045735
PercentMarried	-.302479	-.429315	0.100569	0.061827	0.063229	0.179643	0.164986	0.388643	-.362185	-.548219	0.159036	0.196752
PctHS25_Over	0.234879	-.502171	-.048459	0.117566	0.031215	0.261818	0.216250	0.396304	0.272552	0.542907	-.113226	0.145909
PctUnemployed16_Over	0.376176	0.183562	-.024486	-.002004	0.155240	0.016513	0.308519	-.002961	-.720313	0.304641	0.301340	-.046537
PctPrivateCoverage	-.444781	-.040788	-.264904	0.089345	0.006931	0.008132	0.010464	-.217142	0.174396	0.265848	0.724554	0.221150
BirthRate	-.101926	-.181544	0.789982	0.095971	-.082495	-.284125	0.357005	-.293599	0.075802	0.115029	0.056345	-.005767

Vemos que los resultados de los autovalores y los autovectores con la base de datos que contiene los outliers varía con los resultados obtenidos sin outliers por lo que podemos **optar por los resultados sin los outliers**, en el que hemos seleccionado que nos hemos quedado con 5 factores.

4.3) Hacer de nuevo el análisis sobre la matriz de correlaciones pero ahora indicando el número de componentes principales que hemos decidido retener y con la opción que nos permite obtener todos los gráficos. Sobre este análisis contestar los siguientes apartados:

a. *Mostrar los coeficientes para obtener las componentes principales ¿Cuál es la expresión para calcular la Primera Componente en función de las variables originales?*

```
PROC PRINCOMP
DATA=no_super.cancer_sin_outliers   OUTSTAT=Stat  OUT=results n=5;
var deathRate medIncome popEst2015 povertyPercent studyPerCap MedianAge
AvgHouseholdSize PercentMarried PctHS25_Over PctUnemployed16_Over
PctPrivateCoverage BirthRate;
RUN;
```

Eigenvectors												
	Prin1	Prin2	Prin3	Prin4	Prin5	Prin6	Prin7	Prin8	Prin9	Prin10	Prin11	Prin12
deathRate	-.312253	0.026063	-.166101	0.330664	0.386343	-.411799	0.443594	-.208212	-.439736	-.111618	0.003736	0.009113
medIncome	0.432922	-.180374	0.001878	0.275257	0.118371	-.013900	0.067866	-.233570	0.153050	0.156535	-.467258	0.603864
popEst2015	0.157226	-.396381	-.157457	0.212140	0.106828	0.502144	0.406932	0.534370	-.109464	-.101504	0.095234	-.048006
povertyPercent	-.458551	-.102346	0.088399	-.212125	-.158694	0.074339	-.061014	0.138324	-.142630	-.194331	0.227513	0.750339
studyPerCap	0.021968	-.172034	-.494783	-.502216	0.615959	-.057901	-.270638	0.088705	0.054036	0.040129	-.053198	0.040717
MedianAge	-.003527	0.524356	-.210437	0.120017	0.082418	0.449575	-.096599	-.065314	-.344055	0.536805	0.135428	0.137727
AvgHouseholdSize	-.005338	-.352700	0.472424	0.339481	0.338298	-.054536	-.530196	0.078175	-.209559	0.183351	0.228343	-.053211
PercentMarried	0.277551	0.414927	0.086928	0.124518	0.278575	0.226645	-.192686	-.075632	-.048464	-.738199	0.065861	0.065543
PctHS25_Over	-.242395	0.395925	0.080509	0.264782	0.246133	-.205971	0.029633	0.557702	0.510731	0.117295	-.092736	0.098883
PctUnemployed16_Over	-.367187	-.170947	-.083405	0.201589	0.177237	0.381110	0.064127	-.505026	0.539750	-.009973	0.240801	-.055853
PctPrivateCoverage	0.441659	0.024352	-.185356	0.056232	-.059055	-.338889	0.113380	-.012474	0.174566	0.083668	0.754470	0.169654
BirthRate	0.117840	0.107305	0.610058	-.462177	0.355529	0.101130	0.458960	-.084874	0.025978	0.160584	0.085819	0.022766

La expresión para calcular la Primera Componente en función de las variables originales es:

$$Prin1 = e_{1\,1} \cdot deathRate + e_{2\,1} \cdot medIncome + e_{3\,1} \cdot popEst2015 + \cdots + e_{12\,1} \cdot BirthRate$$

Donde cada e_i son lo auto vectores, que aplicado a este caso sería:

$$Prin1 = -0.311089 \cdot deathRate + 0.432922 \cdot medIncome + 0.157226 \cdot popEst2015 + \cdots + 0.117840 \cdot BirthRate$$

Además, podemos observar que las variables que tienen mayor peso en la primera componente son **deathRate, medIncome, povertyPercent, PctUnemployed16_Over y PctPrivateCoverage,** porque son las que tienen coeficientes con una magnitud mayor**.**

b. Mostar una tabla con las correlaciones de las Variables con las Componentes Principales. Para cada Componente indicar las variables con las que está más correlacionada.

En este apartado es queremos obtener la matriz de cargas. Para obtener las correlaciones de las variables con cada componente es necesario realizar:

$$corr_{xj} = e_{xj} \cdot \sqrt{\lambda_x}$$

- $\boldsymbol{corr_{xj}}$: *es la correlación de la componente x con la variable* j
- e_{xj}: *es el* coeficiente (*peso o valor de carga*) *que tiene la variable j en la componente* x.
- $\sqrt{\boldsymbol{\lambda_x}}$: *raíz del autovalor asociado a la componente* x.

```
PROC PRINCOMP
DATA=no_super.cancer_sin_outliers   OUTSTAT=Stat n=5 OUT=results
plots=all;
var deathRate medIncome popEst2015 povertyPercent studyPerCap MedianAge
AvgHouseholdSize PercentMarried PctHS25_Over PctUnemployed16_Over
PctPrivateCoverage BirthRate;
```

```
ods output Eigenvalues = autovalores;
ods output Eigenvectors = autovectores;
RUN;
```

Añadimos al código anterior las opciones `ods output Eigenvalues = autovalores` y `ods output Eigenvectors = autovectores` para que nos guarde en una tabla los autovectores y las variables "Autovectores" y en otra las variables y los autovalores "autovalores".

```
DATA correlaciones (drop = label);
SET autovectores;
cor1 = Prin1*sqrt(3.82185605);
cor2 = Prin2*sqrt(2.37440522);
cor3 = Prin3*sqrt(1.13030207);
cor4 = Prin4*sqrt(1.05132283);
cor5 = Prin5*sqrt(0.86155580);
RUN;

PROC PRINT DATA=correlaciones;
VAR Variable cor1--cor5;
RUN;
```

Obs	Variable	cor1	cor2	cor3	cor4	cor5
1	deathRate	-0.61044	0.04016	-0.17659	0.33904	0.35860
2	medIncome	0.84634	-0.27794	0.00200	0.28223	0.10987
3	popEst2015	0.30737	-0.61079	-0.16740	0.21752	0.09916
4	povertyPercent	-0.89645	-0.15771	0.09398	-0.21750	-0.14730
5	studyPerCap	0.04295	-0.26509	-0.52603	-0.51494	0.57173
6	MedianAge	-0.00689	0.80799	-0.22373	0.12306	0.07650
7	AvgHouseholdSize	-0.01044	-0.54348	0.50226	0.34808	0.31401
8	PercentMarried	0.54260	0.63937	0.09242	0.12767	0.25857
9	PctHS25_Over	-0.47387	0.61009	0.08559	0.27149	0.22846
10	PctUnemployed16_Over	-0.71784	-0.26341	-0.08867	0.20670	0.16451
11	PctPrivateCoverage	0.86342	0.03752	-0.19706	0.05766	-0.05482
12	BirthRate	0.23037	0.16535	0.64859	-0.47389	0.33000

Las variables más correlacionadas con las componentes son:

- Para la **primera componente** son deathRate, medIncome, povertyPercent, PctUnemployed16_Over y PctPrivateCoverage.
- Para la **segunda componente** son popEst2015, MedianAge, AvgHouseholdSize, PercentMarried y PctHS25_Over.
- Para la **tercera componente** son AvgHouseholdSize y PctHS25_Over.
- Para la **cuarta componente** son BirthRate y studyPerCap.

- Para la **quinta componente** la más correlacionada es studyPerCap.

Vemos que tal y como es propio del análisis de componentes principales, el primer factor es el que contienen más variables correlacionadas (es casi como un índice) y a medida que avanzamos el número de variables que explican los factores disminuye.

c. *Interpretar el gráfico que representa las correlaciones de cada componente con las variables intentando explicar lo que representa cada componente.*

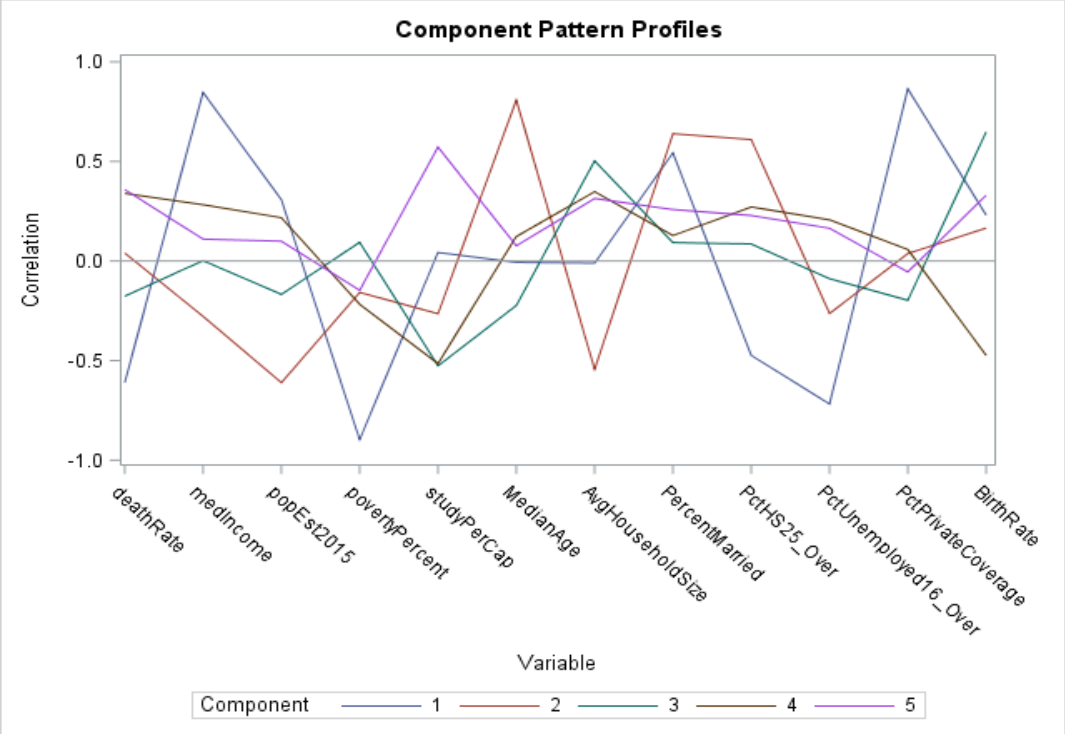

En este gráfico que nos saca el código con la opción `plots=all` se representa la tabla que hemos calculado en el apartado anterior. Cada línea de colores representa una componente y en el eje Y se representa el rango de los coeficientes de correlación que van desde -1 a 1. Además, se añade una línea gris horizontal en el 0 que indicaría que no habría correlación entre la variable y la componente.

Cada pico en las líneas indica donde se alcanza el coeficiente que tiene cada variable para la primera componente, por ejemplo, deathRate tenía un coeficiente de -0.61 y medIncome de 0.85 como se ve en los dos primeros picos del gráfico de la línea azul.

Esto nos permite ver de forma más directa con los picos más extremos que variables están más correlacionadas con las componentes.

d. Comentar los gráficos en donde se representan las variables en los planos formados por las componentes.

Los gráficos de las variables frente a las componentes nos ayudan a visualizar cuáles son las variables que mejor explican y más correlacionadas están con las componentes.
Estos gráficos son:

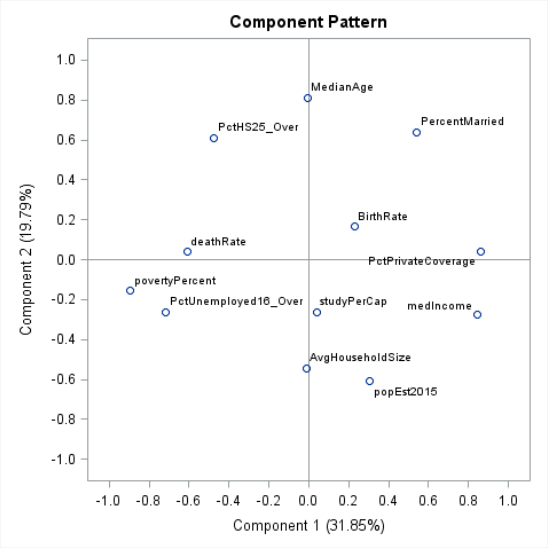

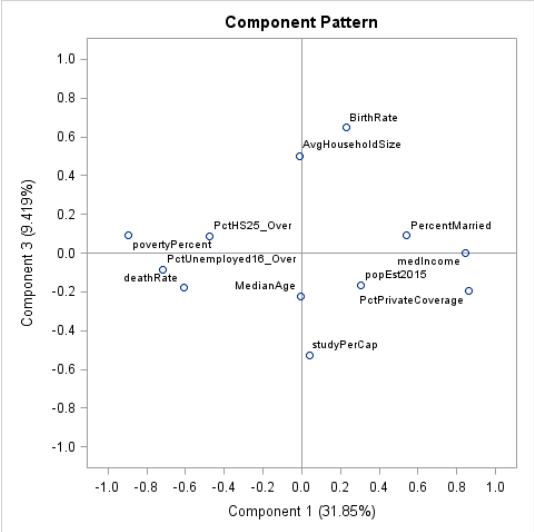

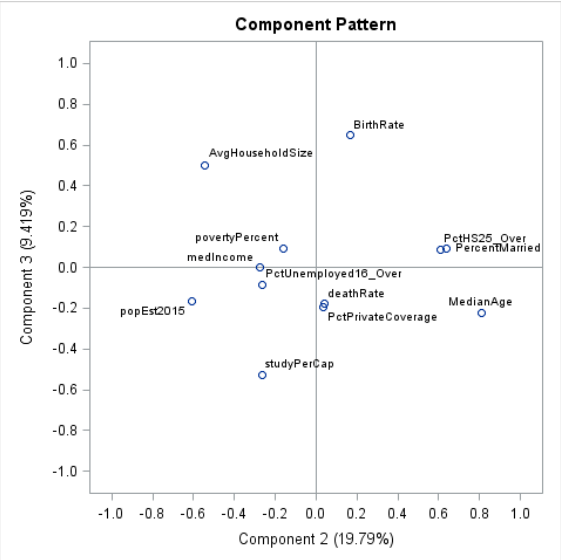

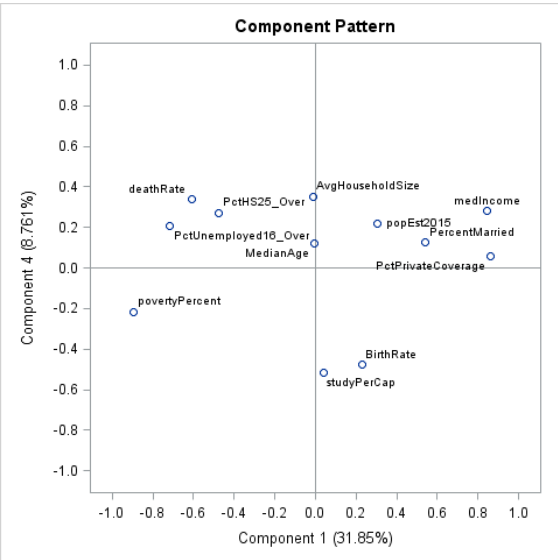

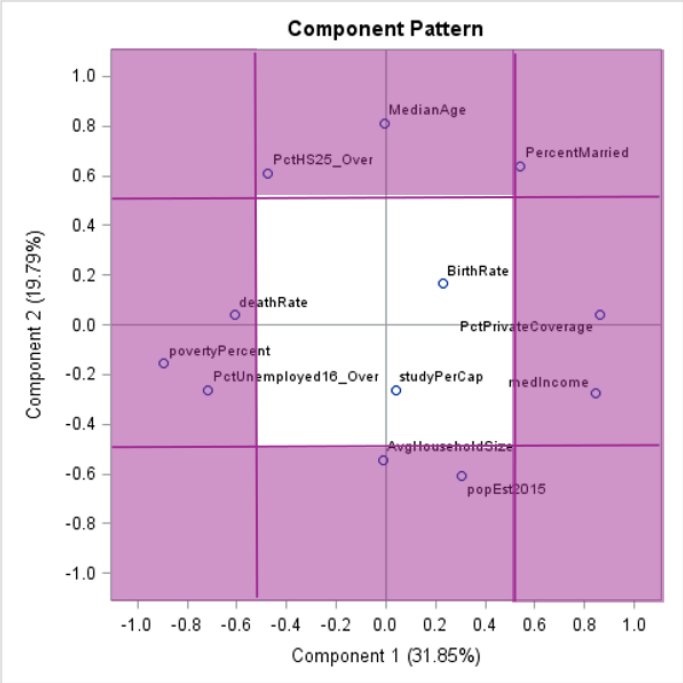

Vamos a comentar el gráfico de los dos primeros factores ya que son los más relevantes, debido a que estaban explicados por un mayor número de variables. Se ha coloreado en morado aquellas franjas que son más significativas a la hora de la interpretación, ya que en el cuadrado central se sitúan aquellas variables que tenían muy poca correlación en los dos componentes (cargas cercanas a 0).

En el gráfico se representan las cargas de cada variable para cada componente. Si nos centramos en la ***primera componente*** (es decir, mirando el eje X), vemos que las variables más correlacionadas con este componente son aquellas con cargas mayores a 0.5 y -0.5 (correlación negativa), en concreto, **PercentMarried, PctPrivateCoverage, medIncome , povertyPercent y PctUnemployed16_Over.**

Por otro lado, para la ***segunda componente*** nos fijamos en el eje Y para ver que las variables que mejor se explican en esta componente son **popEst2015, PctHS25_Over, PercentMarried y MedianAge.**

5. Realizar un Análisis Factorial sobre la matriz de correlaciones, el número de factores necesario para que el porcentaje de varianza explicada sea al menos del 70%.

Parte I. Sin rotación

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL;
```

```
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Eigenvalues of the Correlation Matrix: Total = 12 Average = 1				
	Eigenvalue	Difference	Proportion	Cumulative
1	3.82185605	1.44745083	0.3185	0.3185
2	2.37440522	1.24410315	0.1979	0.5164
3	1.13030207	0.07897924	0.0942	0.6105
4	1.05132283	0.18976703	0.0876	0.6982
5	0.86155580	0.10973058	0.0718	0.7700
6	0.75182522	0.05683628	0.0627	0.8326
7	0.69498893	0.22444823	0.0579	0.8905
8	0.47054070	0.14345783	0.0392	0.9297
9	0.32708287	0.07739971	0.0273	0.9570
10	0.24968316	0.07724488	0.0208	0.9778
11	0.17243828	0.07843942	0.0144	0.9922
12	0.09399886		0.0078	1.0000

Para explicar al menos un 70% de varianza debemos quedarnos con 5 factores.

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL n=5;
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

1) *¿Cuánto vale el índice KMO? ¿Es un valor adecuado para poder realizar el Análisis factorial?*

Kaiser's Measure of Sampling Adequacy: Overall MSA = 0.74118472											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.79124321	0.73195914	0.82374803	0.75379122	0.51444501	0.58980223	0.51726531	0.75374459	0.74440093	0.82552494	0.80332375	0.54736465

Con 5 factores, hemos conseguido un KMO medio de 0.74118 donde los índices de todas las variables son mayores que 0.5 así que podemos continuar con el Análisis factorial y no es necesario eliminar ninguna variable, es decir, no parece haber ninguna variable independiente de las demás.

2) *¿Qué variable eliminarías del modelo para mejorar el índice KMO? Realizar el análisis sin esa variable, ¿Cuánto vale ahora el índice KMO? ¿Ha mejorado el índice KMO? Decidir si hacer el análisis con o sin esa variable.*

No obstante, para poder mejorar el índice KMO eliminaríamos **studyPerCap** que es la que había obtenido un menor índice KMO en la salida anterior. Si realizamos el análisis de nuevo sin esta variable, el índice KMO ahora quedaría:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL n=5;
      VAR deathRate medIncome popEst2015 povertyPercent /*studyPerCap*/
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
```

```
RUN;
```

Kaiser's Measure of Sampling Adequacy: Overall MSA = 0.74615957										
deathRate	medIncome	popEst2015	povertyPercent	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.79403580	0.74298381	0.82710183	0.75572794	0.58571291	0.51293368	0.75132770	0.75915270	0.82703550	0.80238221	0.54505371

Ahora el índice de KMO vale 0.746, ha mejorado 0.006 respecto al anterior. De este modo, la mejora es apenas significativa por lo que de momento no merece la pena eliminar la variable **studyPerCap** del análisis ya que su KMO sigue estando por encima de 0.5 y al eliminarla el resultado no presentan grandes mejoras.

3) *Realizar un análisis factorial sobre la matriz de correlaciones utilizando el método de Componentes Principales, el de Factores Principales y el de Máxima Verosimilitud.*

- **MÉTODO DE COMPONENTES PRINCIPALES** : METHOD=PRINCIPAL

Partimos del código anterior:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL n=5;
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Root Mean Square Off-Diagonal Residuals: Overall = 0.07276828											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.09474726	0.03692663	0.08937891	0.03223119	0.05723197	0.08247754	0.09201195	0.06072355	0.06705987	0.07351950	0.06660716	0.08720298

En el que obtenemos que el KMO de todas las variables es mayor a 0.5 (como hemos mostrado en el apartado 5.1) pero el RMSR es superior a 0.07 por lo que deberemos aumentar el número de factores.

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL n=6;
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Root Mean Square Off-Diagonal Residuals: Overall = 0.06317815											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.08320022	0.03683308	0.08474600	0.02870667	0.05594414	0.04409802	0.09169208	0.04850085	0.06156637	0.05968164	0.03349029	0.08546788

Aumentando a 6 factores no conseguimos que los residuales de todas las variables sean menores que 0.07. Por ello, debemos seguir aumentando el número de factores a 7:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA
METHOD=PRINCIPAL PRIORS=ONE REORDER RESIDUAL n=7;
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Kaiser's Measure of Sampling Adequacy: Overall MSA = 0.74118472											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.79124321	0.73195914	0.82374803	0.75379122	0.51444501	0.58980223	0.51726531	0.75374459	0.74440093	0.82552494	0.80332375	0.54736465

Final Communality Estimates: Total = 10.686256											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.91323278	0.88862476	0.85736399	0.91306589	0.99429653	0.88238038	0.96510964	0.85932655	0.76249156	0.77438190	0.88734981	0.98863233

Root Mean Square Off-Diagonal Residuals: Overall = 0.04142008											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.04625517	0.03493118	0.06402616	0.02649737	0.01421018	0.04095614	0.02780633	0.03798091	0.06146745	0.05915496	0.02733821	0.01750094

Ya hemos conseguido que los residuales de todas las variables sean menores a 0.07 y que el KMO y la comunalidad final de cada una de ellas sea mayor a 0.5.

- **MÉTODO DE FACTORES PRINCIPALES** : METHOD=PRINIT

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4;
      VAR deathRate medIncome popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Root Mean Square Off-Diagonal Residuals: Overall = 0.03456510											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.04551787	0.01518295	0.02968587	0.01363137	0.02769214	0.04763033	0.01801825	0.03511916	0.04734331	0.03985134	0.04369074	0.02521058

Final Communality Estimates: Total = 6.600735											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.40401719	0.94054350	0.34417794	0.91514770	0.06774234	0.58721940	0.52508385	0.73815297	0.56032307	0.59866209	0.75152911	0.16813609

Kaiser's Measure of Sampling Adequacy: Overall MSA = 0.74118472											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.79124321	0.73195914	0.82374803	0.75379122	0.51444501	0.58980223	0.51726531	0.75374459	0.74440093	0.82552494	0.80332375	0.54736465

En el método de Factores Principales (PRINIT) hemos obtenido que con 4 factores el RMSR y el índice KMO son buenos pero, las comunalidades finales son muy bajas en prácticamente todas las variables, por lo que vamos a eliminar la variable **studyPerCap** que era la que tenía un KMO más bajo para ver cómo afecta a la demás comunalidades:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4;
      VAR deathRate medIncome popEst2015 povertyPercent /*studyPerCap*/
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate;
RUN;
```

Final Communality Estimates: Total = 6.530052											
deathRate	medIncome	popEst2015	povertyPercent	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.41100450	0.96087110	0.33197268	0.89230158	0.58553755	0.37625770	0.86811405	0.49443519	0.61318347	0.82231252	0.17406150

Eliminando esta variable han aumentado significativamente las comunalidades finales, aunque la de **BirthRate, popEst2015 y la de AvgHouseholdSize** siguen siendo muy bajas, puesto que están muy por debajo del 0.5.
Por ello, dado que estas variables eran las que siguientes en tener un KMO menor, las eliminamos una a una del modelo hasta obtener:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4;
      VAR deathRate medIncome /*popEst2015*/ povertyPercent
/*studyPerCap*/ MedianAge /*AvgHouseholdSize*/ PercentMarried
PctHS25_Over PctUnemployed16_Over PctPrivateCoverage /*BirthRate*/;
RUN;
```

Kaiser's Measure of Sampling Adequacy: Overall MSA = 0.74648783							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.77473645	0.71887416	0.72475132	0.53912869	0.75753663	0.71250950	0.80800622	0.84024467

Root Mean Square Off-Diagonal Residuals: Overall = 0.00839109							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.00334709	0.01147532	0.00915813	0.00864066	0.01092224	0.00671440	0.00445837	0.00880963

Final Communality Estimates: Total = 6.022317							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.77752774	0.87557406	0.93809784	0.61061080	0.72078586	0.53820507	0.81169703	0.74981847

- **MÉTODO DE MÁXIMA VEROSIMILITUD** : METHOD=ML

```
%NORMAL_MULT(DATA=no_super.cancer_sin_outliers, var= deathRate medIncome
popEst2015 povertyPercent studyPerCap
MedianAge AvgHouseholdSize PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage BirthRate);
```

Obs	Y1	Y2	ACUMULADO	DIFERENCIA	REFERENCIA	HIPOTESIS
1	8.43842	14.8454	0.25910	0.24090	0.069412	Norm. rechazada

Dado que el método de Máxima Verosimilitud requiere que se cumpla la normalidad y en este caso no se cumple, no podemos realizar este método y queda descartado.

❖ COMPARACIÓN DE MÉTODOS

Para comparar los dos modelos resultantes es necesario que ambos tengan el mismo número de factores por lo que para realizar la comparación, aumentamos el de Factores Principales a 7 factores:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=7;
      VAR deathRate medIncome /*popEst2015*/ povertyPercent
/*studyPerCap*/ MedianAge
        /*AvgHouseholdSize*/ PercentMarried PctHS25_Over
PctUnemployed16_Over PctPrivateCoverage /*BirthRate*/;
RUN;
```

Final Communality Estimates: Total = 7.792654							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.99994677	0.94138172	0.87121820	0.99518528	0.99803673	0.99876138	0.99910946	0.98901443

Y para el de Componentes Principales hemos obtenido que:

Final Communality Estimates: Total = 10.686256											
deathRate	medIncome	popEst2015	povertyPercent	studyPerCap	MedianAge	AvgHouseholdSize	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage	BirthRate
0.91323278	0.88862476	0.85736399	0.91306589	0.99429653	0.88238038	0.96510964	0.85932655	0.76249156	0.77438190	0.88734981	0.98863233

De este modo, aunque hemos obtenido mejores comunalidades en el método de Componentes Principales, sabemos que en el de Factores Principales (PRINIT) aún con menos factores nos sigue asegurando que los errores son menores a 0.07, KMO>0.5 y que obtenemos buenas comunalidades finales. Por ello, el método seleccionado es el de Factores Principales.

5.3.1) Para el mejor método:

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4 plots=all;
      VAR deathRate medIncome /*popEst2015*/ povertyPercent
/*studyPerCap*/ MedianAge /*AvgHouseholdSize*/ PercentMarried
PctHS25_Over PctUnemployed16_Over PctPrivateCoverage /*BirthRate*/;
RUN;
```

a. ¿Qué porcentaje de la varianza queda explicado con estos factores?

Variance Explained by Each Factor			
Factor1	Factor2	Factor3	Factor4
3.5245266	1.4739617	0.6285919	0.3952366

Dada la tabla que nos proporciona SAS y sabiendo que el porcentaje de varianza lo obtenemos como:

$$\%varianzaFactorj = \lambda_j / varianzaTotal$$

Entonces:

$$\%\text{varianzaFactor1} = \lambda_1/8 = (3{,}5245266/8) * 100 = 44.6\%$$
$$\%\text{varianzaFactor2} = \lambda_2/8 = (1{,}4739617/8) * 100 = 18.42\%$$
$$\%\text{varianzaFactor3} = \lambda_3/8 = (0{,}6285919/8) * 100 = 7.86\%$$
$$\%\text{varianzaFactor1} = \lambda_4/8 = (0{,}3952366/8) * 100 = 4.94\%$$

Y esto da un total de 75,28%, es decir, que con 4 factores estamos siendo capaces de explicar el 75.28% de la varianza total.

b. Comentar el resultado de los gráficos que representan la relación entre las variables y los Factores (PATHDIAGRAM). ¿Qué grupos de variables quedan mejor representados con cada uno de los factores?

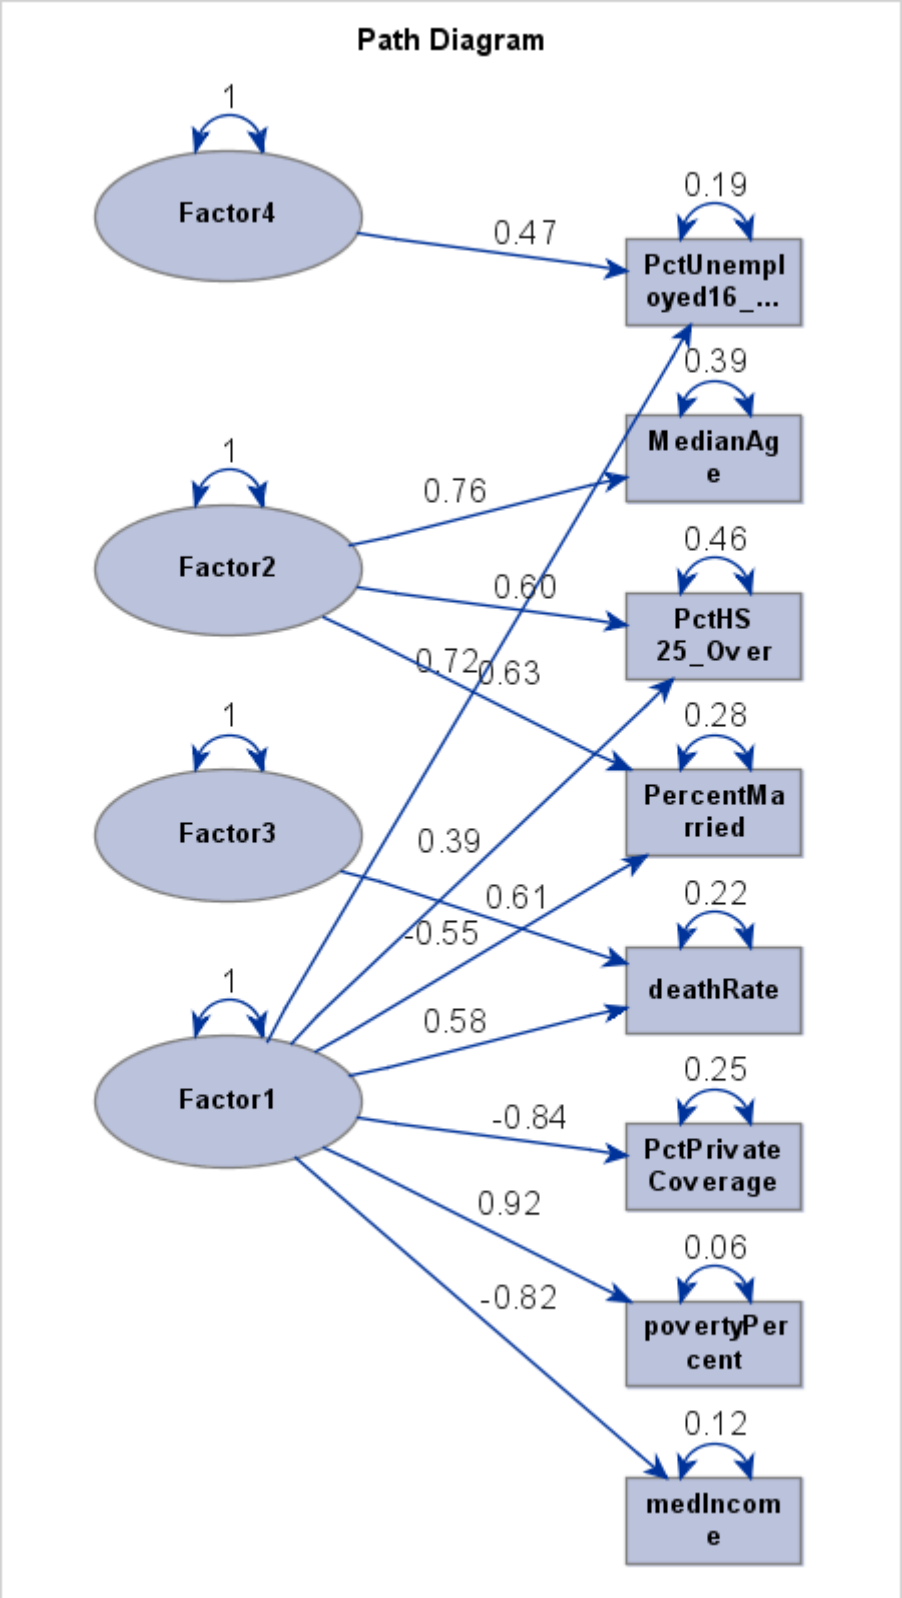

En el PATHDIAGRAM podemos observar que a la izquierda tenemos los 4 factores que hemos retenido conectados con las variables, que aparecen a la derecha, mediante flechas. Sobre ellas, podemos ver unos números que hacen referencia a los valores de carga entre los factores y las variables.

Para el Factor 1 las variables mejor representadas son medIncome, povertyPercent, PctPrivateCoverage, deathRate, PercentMarried, y PctUnemployed16_Over.
En el Factor 2 las mejores representadas son PercentMarried, PctHS25_Over y MedianAge.
En el Factor 3 la mejor representada es deathRate y en el último Factor PctUnemployed16_Over.

c. Representar los gráficos de las variables en los planos factoriales y comentar la relación entre los factores y las variables.

Factor Pattern				
	Factor1	Factor2	Factor3	Factor4
povertyPercent	0.91791	-0.14236	-0.26629	-0.06602
PctUnemployed16_Over	0.71834	-0.12801	0.24941	0.46594
medIncome	-0.82069	-0.28601	0.29716	0.17869
PctPrivateCoverage	-0.83688	-0.06135	0.13219	-0.16795
MedianAge	-0.04379	0.76134	-0.06520	0.15751
PercentMarried	-0.55275	0.62729	-0.03572	0.14314
PctHS25_Over	0.38506	0.59683	0.11385	-0.14410
deathRate	0.57993	0.14971	0.60927	-0.21813

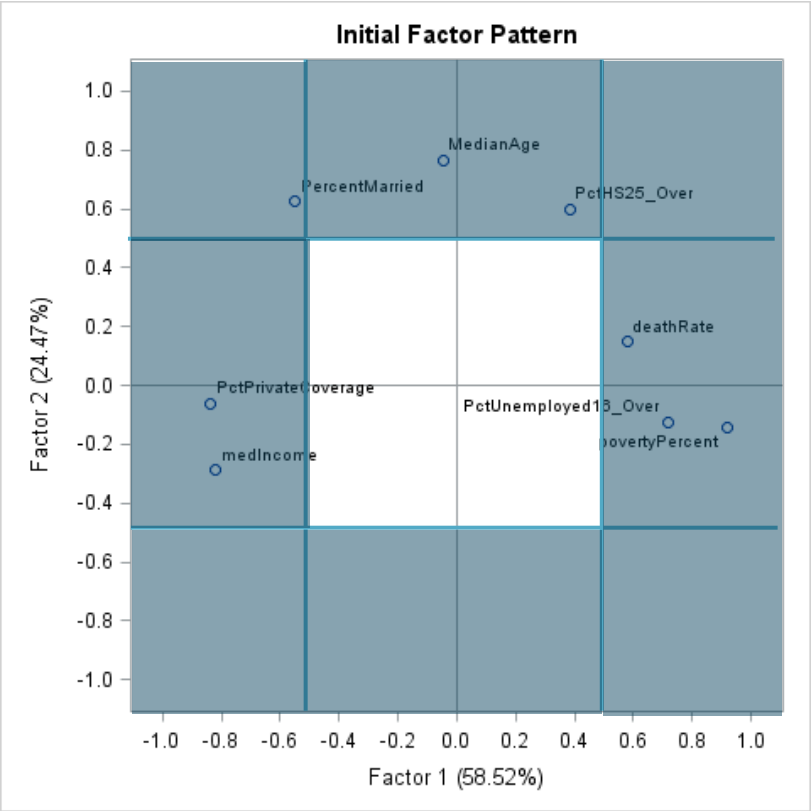

Nuevamente volvemos a comentar el gráfico de los dos primeros factores, ya que como podemos ver en la matriz de cargas, son las que más variables correlacionadas tienen.

En este gráfico, al igual que comentamos para Componentes Principales, aquí se representan las cargas factoriales de cada variable en cada factor. De este modo, las variables más relevantes son aquellas de los extremos en las que se alcanzan correlaciones más altas.

En el Factor 1, las variables mejor explicadas con deathRate, PctUnemployed16_Over, PovertyPercent, medIncome, PctPrivateCoverage y PercentMarried. Esta última tiene una carga cercana al 0.5.

En el Factor 2, las mejor explicadas son PercentMarried, medianAge y PctHS25_Over.

Con estos gráficos, ya podemos ir observando que cuando rotemos, veremos como las variables se ajustan a los ejes que mejor las explican.

d. ¿La comunalidad de todas las variables se encuentra bien representada?

Final Communality Estimates: Total = 6.022317							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.77752774	0.87557406	0.93809784	0.61061080	0.72078586	0.53820507	0.81169703	0.74981847

Con este método, obtenemos una comunalidad total de 6.022317; es decir, está explicando un 6.02 % de la varianza.

Atendiendo cada una de las variables de manera individual, tenemos que los 4 factores que hemos escogido consiguen explicar muy bien la variabilidad de estas, pues su comunalidad se encuentra por encima del 0.70, salvo en PctHS25_Over (0.53) y en MedianAge (0.61).

Aunque la mayoría de variables están muy bien representada, la comunalidad final es muy baja.

PARTE II. CON ROTACIÓN

4) *Con el número de factores utilizados en el análisis factorial anterior (sin rotación), realiza una rotación VARIMAX y otra QUARTIMAX. Con la que ofrezca mejores resultados, responde los siguientes apartados:*

```
PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4 plots=all
ROTATE=VARIMAX;
      VAR deathRate medIncome /*popEst2015*/ povertyPercent
/*studyPerCap*/ MedianAge /*AvgHouseholdSize*/ PercentMarried
PctHS25_Over PctUnemployed16_Over PctPrivateCoverage /*BirthRate*/;
   RUN;

PROC FACTOR data=no_super.cancer_sin_outliers  SIMPLE MSA  EIGENVECTORS
METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL MAXITER=100 N=4 plots=all
ROTATE=QUARTIMAX;
      VAR deathRate medIncome /*popEst2015*/ povertyPercent
/*studyPerCap*/ MedianAge /*AvgHouseholdSize*/ PercentMarried
PctHS25_Over PctUnemployed16_Over PctPrivateCoverage /*BirthRate*/;
RUN;
```

QUARTIMAX

Rotated Factor Pattern				
	Factor1	Factor2	Factor3	Factor4
medIncome	0.89257	-0.19092	-0.08468	0.18780
PctPrivateCoverage	0.83580	-0.01991	-0.05678	-0.21824
povertyPercent	-0.94335	-0.21840	0.02060	-0.00786
MedianAge	-0.03077	0.78060	-0.00089	0.01800
PercentMarried	0.46928	0.69403	-0.13027	-0.04368
PctHS25_Over	-0.37191	0.50998	0.36026	-0.10010
deathRate	-0.36912	0.00243	0.79337	0.10875
PctUnemployed16_Over	-0.58615	-0.12959	0.20432	0.63999

VARIMAX

Rotated Factor Pattern				
	Factor1	Factor2	Factor3	Factor4
medIncome	0.88876	-0.13167	-0.10517	-0.23933
PctPrivateCoverage	0.70381	0.00843	-0.47728	-0.16309
povertyPercent	-0.86778	-0.26324	0.30810	0.14431
MedianAge	-0.06642	0.77679	-0.00753	0.05232
PercentMarried	0.36462	0.71700	-0.22706	-0.14898
PctHS25_Over	-0.34739	0.46466	0.01222	0.44885
PctUnemployed16_Over	-0.30610	-0.12639	0.80519	0.23171
deathRate	-0.17991	-0.05008	0.24179	0.82716

Se ha subrayado en morado aquellos valores en los que se han obtenido mejores resultados en QUARTIMAX y en azul en los que los resultados de VARIMAX eran mayores. Podemos comprobar que en líneas generales hemos obtenido mejores resultados con QUARTIMAX por lo que nos quedamos con este método de rotación.

*a) Comparar el **nuevo Pathdiagram** con el obtenido antes de la rotación. ¿Qué coeficientes han cambiado y cuales permanecen iguales?*

CON ROTACIÓN:

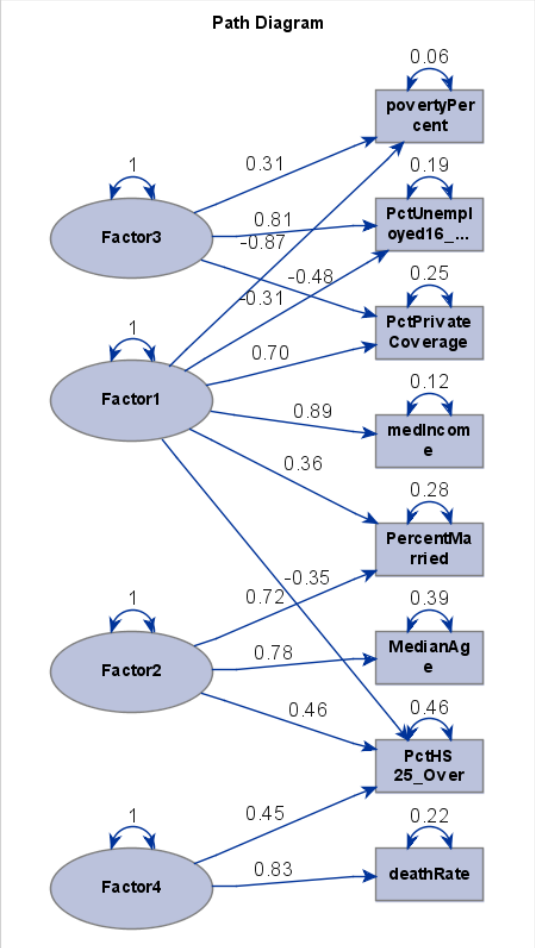

SIN ROTACIÓN:

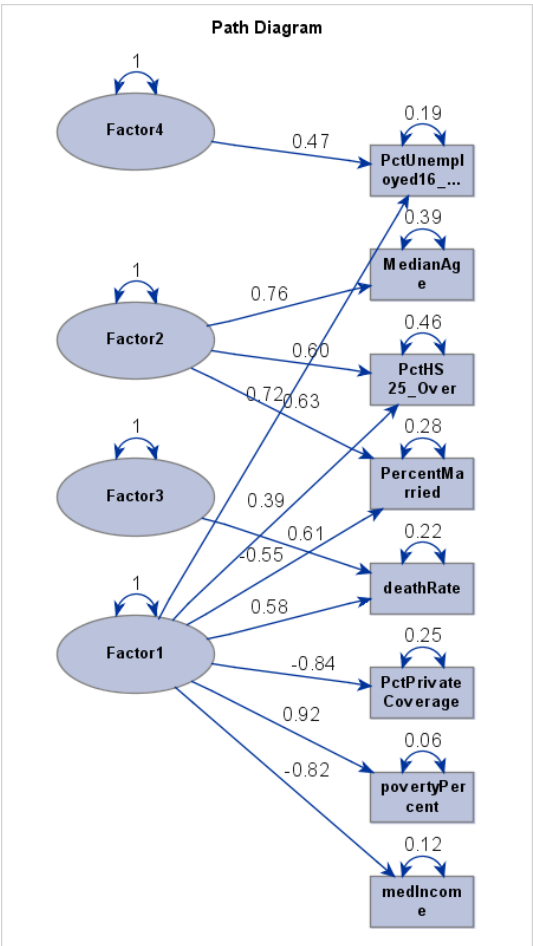

Al comparar ambos gráficos se puede ver cómo se han reorganizado los nodos de la izquierda y las figuras de la derecha. Es decir, se ha reorganizado el gráfico de manera que para cada factor se agrupan las variables que mejor explica ese factor.

En la parte sin rotación estaba más difuso este concepto mientras que al rotarlo podemos ver mejor que variables se explican mejor en cada factor para más adelante poder nombrarlos.

b) *Representar los gráficos de las variables en los planos factoriales y comentar la relación entre los factores y las variables. ¿Qué representa cada factor?*

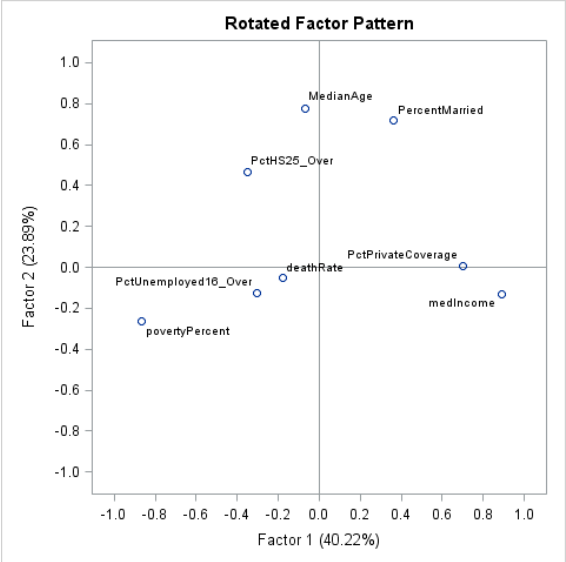

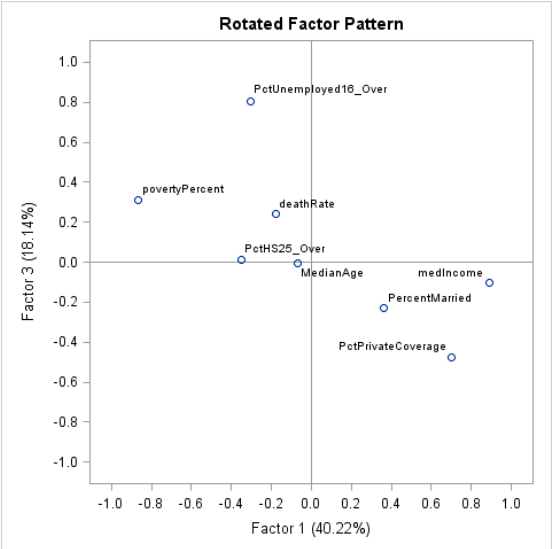

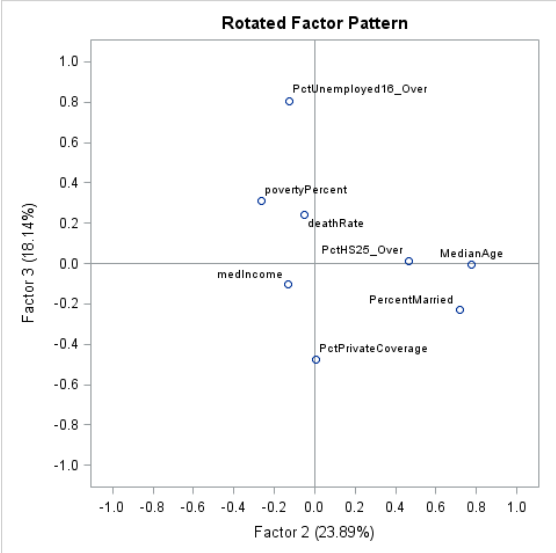

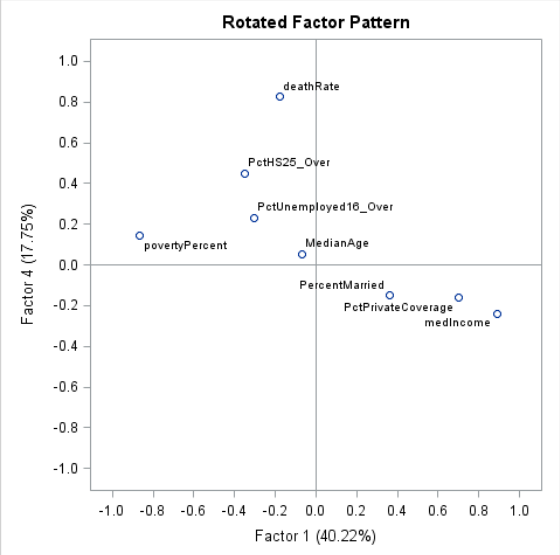

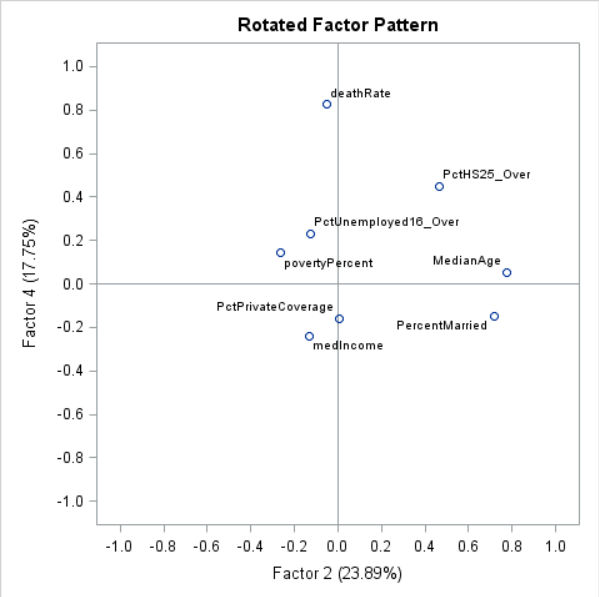

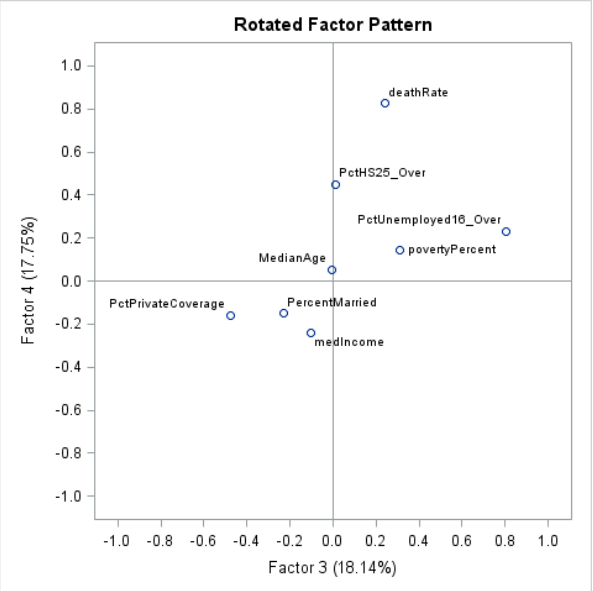

Al hacer la rotación es interesante ver los cambios que realiza frente a los resultados sin rotar. Para comparar estos gráficos vamos a realizarlo con el del Factor 1 y Factor 2:

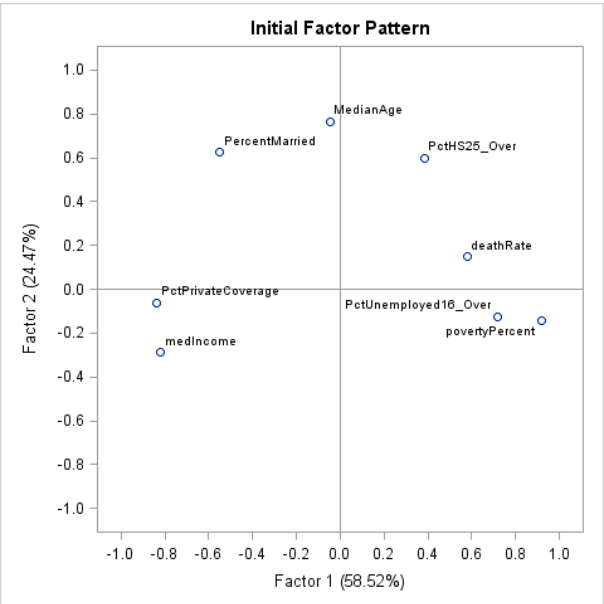

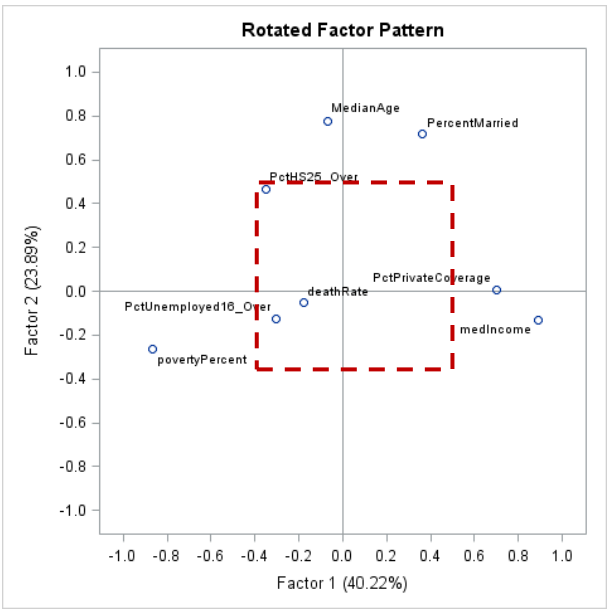

Rotar no cambia la información total explicada (la varianza total de todos los factores). Solo **redistribuye la varianza entre los factores**. La rotación no cambia los datos, sino que le da mucho más peso a un eje y se le quita al otro de forma que le quita peso a las variables que estaban peor explicadas en el Factor, para darle más peso a las variables que mejor explicadas estaban en ese factor y que así los factores representen **grupos más coherentes de variables**.

De esta forma, con la rotación en los gráficos veremos que si una variable está **muy alineada con el eje 1 (horizontal) y en alguno de los extremos**, se asocia principalmente con el **Factor 1**. Por el contrario, si está más **alineada con el eje 2 (vertical) y está algún extremo**, se asocia con el **Factor 2**.

Por otro lado, en el recuadro de líneas discontinuas se encuentran las variables poco representadas en ambos factores, lo que nos indica que estarán mejor explicadas en Factor 3 o en el Factor 4. No obstante, *PctHS25_Over* está al límite por lo que al mirar las matriz de cargas (mejor explicado en el siguiente apartado) hemos podido comprobar que en la que mayor carga tienen es en el Factor 2 por lo que la incluiremos a la hora de nombrar al factor.

Por tanto, como habíamos deducido anteriormente, al comparar el gráfico rotado y sin rotar podemos observar cómo las variables que explicaban mejor el Factor 1 (*PovertyPercent, medIncome, PctPrivateCoverage*) se han ceñido al eje horizontal mientras que para el Factor 2 las variables *PercentMarried, medianAge y PctHS25_Over* se han agrupado en torno al eje vertical.

Con esto podemos pasar a nombrar estos dos factores:

- Sabemos que las variables que definen al primer eje con: *PovertyPercent, medIncome y PctPrivateCoverage* por lo que podemos denominar al Factor 1 como **FACTOR SOCIOECONÓMICO**.

- Para el segundo eje las variables que lo definen son MedianAge, PercentMarried, PctHS25_Over por lo que podemos denominar el segundo Factor como **FACTOR DEMOGRÁFICO.**

c) *Sobre la tabla que contiene las cargas de los factores en las variables marcar para cada factor sobre las variables que más carga.*

Rotated Factor Pattern				
	Factor1	Factor2	Factor3	Factor4
medIncome	0.89257	-0.19092	-0.08468	0.18780
PctPrivateCoverage	0.83580	-0.01991	-0.05678	-0.21824
povertyPercent	-0.94335	-0.21840	0.02060	-0.00786
MedianAge	-0.03077	0.78060	-0.00089	0.01800
PercentMarried	0.46928	0.69403	-0.13027	-0.04368
PctHS25_Over	-0.37191	0.50998	0.36026	-0.10010
deathRate	-0.36912	0.00243	0.79337	0.10875
PctUnemployed16_Over	-0.58615	-0.12959	0.20432	0.63999

Con esta información, también podemos pasar a nombrar al Factor 3 y al Factor 4.

- El tercer eje viene explicado casi en su totalidad por deathRate (tasa de mortalidad) por lo que el FACTOR 3 podemos denominarlo **FACTOR MORTALIDAD**.

- Por su parte, el cuarto eje viene explicado mayoritariamente por PctUnemployed16_Over (Porcentaje de residentes de más de 16 años en paro) por lo que el Factor 4 será **FACTOR PARO**.

d) ¿Cuánto vale la raíz de la media de los cuadrados de los residuales RMSR? ¿Qué nos dice este valor? ¿Qué variable tiene mayor suma de los residuos de sus correlaciones? ¿Qué significa esto?

Root Mean Square Off-Diagonal Residuals: Overall = 0.00839109							
deathRate	medIncome	povertyPercent	MedianAge	PercentMarried	PctHS25_Over	PctUnemployed16_Over	PctPrivateCoverage
0.00334709	0.01147532	0.00915813	0.00864066	0.01092224	0.00671440	0.00445837	0.00880963

Con la raíz de la media de los cuadrados de los residuales (RMSR) podemos comprobar la calidad de las transformaciones que estamos realizando, si la raíz es muy baja significa que los residuos son pequeños y que por tanto el error que estamos cometiendo es bajo.

En este caso, la variable con mayor suma de residuos es *medIncome* con un valor de 0.011. Esto significa que el **modelo factorial no reproduce perfectamente** las **correlaciones** de medIncome con las demás variables. Sin embargo, 0.011 es un valor muy pequeño lo que significa que el ajuste sigue siendo bueno.

e) ¿Qué coeficientes se utilizan para calcular el valor de las observaciones en cada factor utilizando sus valores en las variables iniciales? En la tabla de estos coeficientes marcar aquellos valores más altos (en valor absoluto) para cada factor.

Sabemos que las coordenadas de los factores se obtienen como:

$$\text{Factor j} = e_{\text{i j}} \cdot deathRate + e_{\text{i j}} \cdot medIncome + e_{\text{i j}} \cdot \text{povertyPercent} + \cdots + e_{\text{i j}} \cdot \text{PctPrivateCoverage}$$

Donde los coeficientes "e" son los autovectores asociados a los factores.

Eigenvectors				
	1	2	3	4
deathRate	0.30891	0.12331	0.76847	-0.34696
medIncome	-0.43715	-0.23558	0.37480	0.28424
povertyPercent	0.48893	-0.11726	-0.33587	-0.10501
MedianAge	-0.02332	0.62709	-0.08223	0.25055
PercentMarried	-0.29443	0.51668	-0.04506	0.22768
PctHS25_Over	0.20510	0.49160	0.14360	-0.22921
PctUnemployed16_Over	0.38263	-0.10544	0.31457	0.74114
PctPrivateCoverage	-0.44577	-0.05053	0.16673	-0.26715

De esta forma:

$$\text{Factor 1} = 0.3089 \cdot deathRate \text{ -}0.437 \cdot medIncome + 0.4889 \cdot \text{povertyPercent-}0.023 \cdot \text{MedianAge-}0.29 \cdot \text{PercentMarried} + 0.205 \cdot \text{PctHS25Over} + 0.38 \cdot \text{PctUnemployed16Over-}0.446 \cdot \text{PctPrivateCoverage}$$

6. Seleccionar dos variables del conjunto de datos y transformarlas en variables categóricas para realizar un Análisis de Correspondencia Simple. ¿Existe una relación entre ellas? Justifica la respuesta.

1- DISCRETIZACIÓN DE LA VARIABLE Y EL FACTOR

```
PROC FACTOR data=no_super.cancer_sin_outliers
                  SIMPLE MSA METHOD=PRINIT PRIORS=ONE REORDER RESIDUAL
n=4 MAXITER=100 HEYWOOD ROTATE=varimax
                  OUT=FACTORES OUTSTAT=Estad;
      VAR deathRate medIncome povertyPercent MedianAge PercentMarried
PctHS25_Over PctUnemployed16_Over PctPrivateCoverage;
RUN;
```

Con `OUT=FACTORES` creamos un fichero en el que almacenaremos los factores y las variables para luego poder trabajar con ellas. Discretizaremos el primer Factor y la variable AvgHouseholdSize que habíamos eliminado del estudio anteriormente.

```
proc univariate data=FACTORES noprint;
   var Factor1  AvgHouseholdSize; /*usamos un Factor y una de las
variables que hemos quitado*/
   output out=Percentiles PCTLPTS=25 50 75
PCTLPRE=Factor1_ AvgHouseholdSize_  PCTLNAME=P25 P50 P75;
RUN;
proc print data=Percentiles;run;

/*transformamaos la variable continua a categorica en base a los
percentiles*/
DATA correspondencias;
      SET FACTORES;
      IF Factor1 < = -0.66201 THEN Factor1_REC = 1; /*asiganará 1 si
pertence al 1° cuartil*/
      IF -0.66201 < Factor1 <= -0.054362 THEN Factor1_REC = 2;
/*asiganará 2 si pertence entre el 1° y 2° cuartil*/
      IF -0.054362 < Factor1 <= 0.57481 THEN Factor1_REC = 3; /*asiganará
3 si pertence entre el 2° y 3° cuartil*/
      IF Factor1 > 0.57481 THEN Factor1_REC = 4; /*asiganará 4 si
pertence entre el 3° cuartil*/
      IF Factor1 = . THEN Factor1_REC = .;
RUN;
PROC PRINT; RUN;

DATA correspondencias;
      SET correspondencias;
      IF AvgHouseholdSize < = 2.31 THEN AvgHouseholdSize_REC = 11;
/*asiganará 1 si pertence al 1° cuartil*/
      IF 2.31 < AvgHouseholdSize <= 2.44 THEN AvgHouseholdSize_REC = 12;
/*asiganará 2 si pertence entre el 1° y 2° cuartil*/
      IF 2.44 <  AvgHouseholdSize <= 2.59 THEN AvgHouseholdSize_REC = 13;
/*asiganará 3 si pertence entre el 2° y 3° cuartil*/
      IF AvgHouseholdSize > 2.59 THEN AvgHouseholdSize_REC = 14;
/*asiganará 4 si es mayor que el 3° cuartil*/
      IF AvgHouseholdSize = . THEN AvgHouseholdSize_REC = .;
RUN;
PROC PRINT DATA=correspondencias; RUN;
```

```
/*formateamos para categorizarla y aplicarle el formato*/
PROC FORMAT;
VALUE  Factor1_REC 1='Factor_socieconomico_MuyBajo '
2='Factor_Socieconomico_Bajo ' 3='Factor_socieconomico_Medio '
4='Factor_socieconomico_Alto'  ;
VALUE  AvgHouseholdSize_REC 11='Tamaño_MuyPequeño ' 12='Tamaño_Medio '
13='Tamaño_Alto ' 14='Tamaño_Muygrande'  ;
run;

data no_super.correspondencias1;
set correspondencias;
format Factor1_REC Factor1_REC. ;
format AvgHouseholdSize_REC AvgHouseholdSize_REC. ;
run;
PROC PRINT DATA=no_super.correspondencias1; RUN;
```

2- ¿Existe relación entre las ambas?

```
PROC CORRESP DATA=no_super.correspondencias1 all chi2p OUTC=GRAFICA
PROFILE=ROW; /*usamos perfiles fila, porque nos interesa ver q es lo q
pasa con el factor socioeconómico sabiendo el tamaño q tiene*/
TABLES Factor1_REC, AvgHouseholdSize_REC;
RUN;
```

Inertia and Chi-Square Decomposition

Singular Value	Principal Inertia	Chi-Square	Percent	Cumulative Percent
0.33471	0.11203	52.3195	97.33	97.33
0.05276	0.00278	1.3000	2.42	99.75
0.01713	0.00029	0.1370	0.25	100.00
	0.11511	53.7565	100.00	

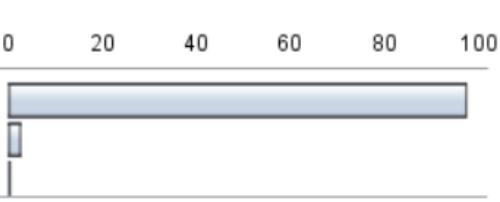

Pr > Chisq < .0001 DF = 9

Con este gráfico podemos comprobar que el p-valor resultante de test de la Chi-Cuadrado nos sale muy pequeño, por lo que existen evidencias significativas para rechazar la hipótesis nula de independencia. Es decir, que existe relación entre el tamaño de las casas y el Factor Socioeconómico.